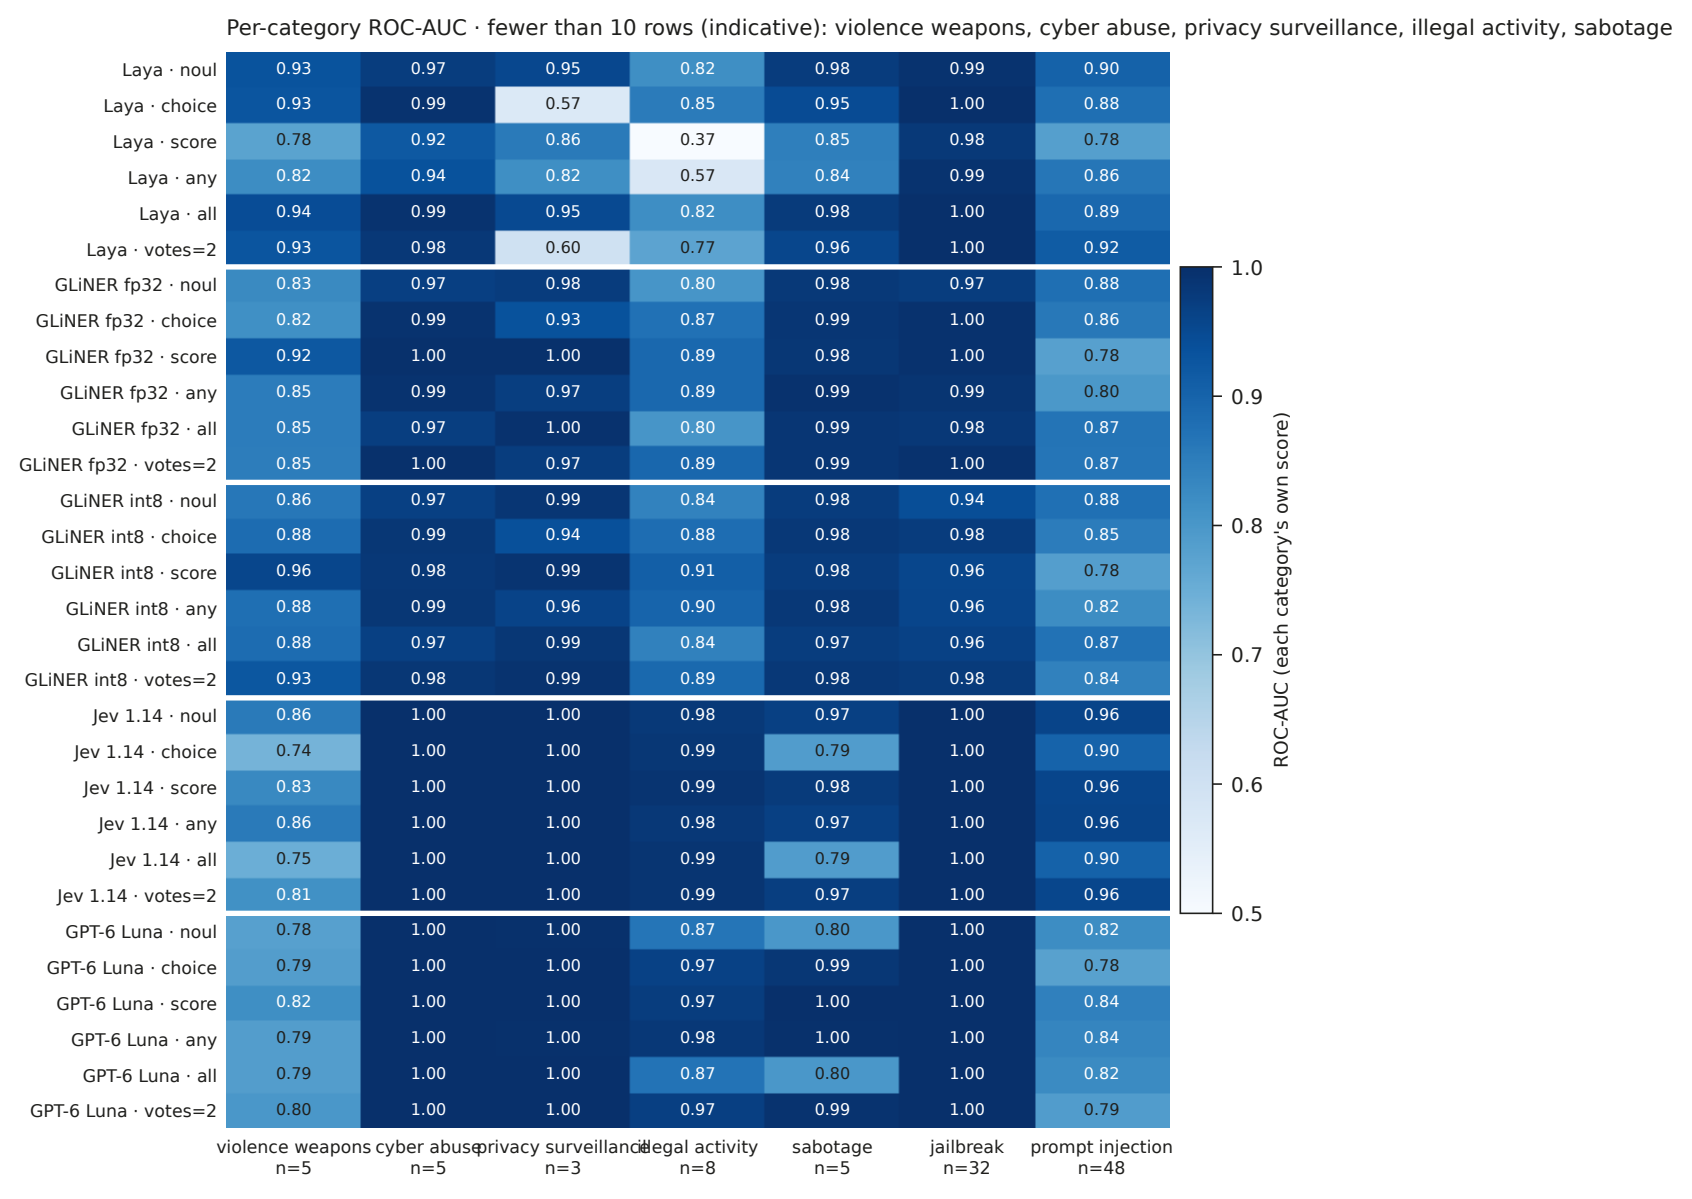
Per-category ROC-AUC · fewer than 10 rows (indicative): violence weapons, cyber abuse, privacy surveillance, illegal activity, sabotage
Laya · noul 0.93 0.97 0.95 0.82 0.98 0.99 0.90
Laya · choice 0.93 0.99 0.57 0.85 0.95 1.00 0.88
Laya · score 0.78 0.92 0.86 0.37 0.85 0.98 0.78
Laya · any 0.82 0.94 0.82 0.57 0.84 0.99 0.86
Laya · all 0.94 0.99 0.95 0.82 0.98 1.00 0.89
Laya · votes=2 0.93 0.98 0.60 0.77 0.96 1.00 0.92
GLiNER fp32 · noul 0.83 0.97 0.98 0.80 0.98 0.97 0.88
GLiNER fp32 · choice 0.82 0.99 0.93 0.87 0.99 1.00 0.86
GLiNER fp32 · score 0.92 1.00 1.00 0.89 0.98 1.00 0.78
GLiNER fp32 · any 0.85 0.99 0.97 0.89 0.99 0.99 0.80
GLiNER fp32 · all 0.85 0.97 1.00 0.80 0.99 0.98 0.87
GLiNER fp32 · votes=2 0.85 1.00 0.97 0.89 0.99 1.00 0.87
GLiNER int8 · noul 0.86 0.97 0.99 0.84 0.98 0.94 0.88
GLiNER int8 · choice 0.88 0.99 0.94 0.88 0.98 0.98 0.85
GLiNER int8 · score 0.96 0.98 0.99 0.91 0.98 0.96 0.78
GLiNER int8 · any 0.88 0.99 0.96 0.90 0.98 0.96 0.82
GLiNER int8 · all 0.88 0.97 0.99 0.84 0.97 0.96 0.87
GLiNER int8 · votes=2 0.93 0.98 0.99 0.89 0.98 0.98 0.84
Jev 1.14 · noul 0.86 1.00 1.00 0.98 0.97 1.00 0.96
Jev 1.14 · choice 0.74 1.00 1.00 0.99 0.79 1.00 0.90
Jev 1.14 · score 0.83 1.00 1.00 0.99 0.98 1.00 0.96
Jev 1.14 · any 0.86 1.00 1.00 0.98 0.97 1.00 0.96
Jev 1.14 · all 0.75 1.00 1.00 0.99 0.79 1.00 0.90
Jev 1.14 · votes=2 0.81 1.00 1.00 0.99 0.97 1.00 0.96
GPT-6 Luna · noul 0.78 1.00 1.00 0.87 0.80 1.00 0.82
GPT-6 Luna · choice 0.79 1.00 1.00 0.97 0.99 1.00 0.78
GPT-6 Luna · score 0.82 1.00 1.00 0.97 1.00 1.00 0.84
GPT-6 Luna · any 0.79 1.00 1.00 0.98 1.00 1.00 0.84
GPT-6 Luna · all 0.79 1.00 1.00 0.87 0.80 1.00 0.82
GPT-6 Luna · votes=2 0.80 1.00 1.00 0.97 0.99 1.00 0.79
violence weapons n=5
cyber abuse n=5
privacy surveillance n=3
illegal activity n=8
sabotage n=5
jailbreak n=32
prompt injection n=48
ROC-AUC (each category's own score)
1.0
0.9
0.8
0.7
0.6
0.5